

专业技能

- 熟悉 LangChain 框架，深入理解 RAG 的 Query 优化、混合检索、重排序等技术；
- 熟悉 Agent 原理及模式；熟悉 MCP 协议、A2A 协议，有多智能体系统开发经验；
- 熟悉主流大模型架构，熟练 LoRA、QLoRA 微调方法；
- 掌握模型压缩技术，包括模型量化与知识蒸馏，具备将预训练模型转化为轻量化、高性能模型的能力；
- 掌握 BERT 系列预训练模型的原理与应用，能利用 Transformers 库针对下游 NLP 任务进行高效微调；
- 熟练掌握 PyTorch 深度学习框架，熟悉 RNN、GRU、LSTM 及 Transformer 等主流模型架构；
- 熟练掌握 Python、NumPy、Pandas 等做数据清洗和可视化工作；
- 掌握 SQL 语言，熟练使用 MySQL、Neo4j、Milvus、Redis 数据库。

工作经历

2021.9-至今

徐辉设计股份有限公司

NLP 算法工程师

工作职责：

- 数据清洗与预处理，构建高质量数据集，用于模型训练；
- 参与 NLP 核心算法研发，包括文本分类、知识图谱构建及大语言模型的微调与优化；
- 探索并落地大模型应用，主导 RAG 系统与 agent 项目的开发，以解决实际业务问题。

项目经历

项目名称：项目全周期服务智能系统

2025.5-至今

项目描述：针对建筑设计师出差（方案汇报、现场协调、项目验收）的信息割裂、审批低效问题，基于多智能体协同架构构建管理系统，融合大语言模型、MCP 与 A2A 协议，覆盖全流程，实现出行查询、智能审批与知识检索，提升企业差旅效率与项目服务智能化水平。

技术栈：MCP、A2A、LangChain、MySQL、Milvus、RAG、GLM-4-32B、LoRA、GPTQ

项目流程：用户交互层 → 上下文管理模块 → 意图识别 Agent → 领域 Agent（出行/审批/汇报/验收）→ 调用 MCP 工具 → 返回结果 → 上下文更新 → 输出至用户界面。

主要职责：

- **智能体设计：**定义意图识别、流程审批、票务查询/预订、项目验收/方案汇报/现场服务等多个核心智能体，明确各智能体的功能边界与交互逻辑，支撑全流程业务场景；
- **MCP Server 构建：**封装酒店、票务、流程审批（企业微信 API）、知识库检索（Milvus+MySQL）等多类 MCP Server，对差旅资源、项目文档等数据进行标准化格式化处理，为智能体提供稳定工具调用能力；

- **Agent Server 构建**: 开发意图识别&槽位提取、票务查询/预订、差旅审批、项目服务等核心智能体。基于 A2A 协议设计“查询-决策-执行”交互逻辑，实现票务闭环、差旅变更自动联动等多智能体协同场景；
- **提示词工程优化**: 针对建筑行业特性，设计各智能体专属提示词（如意图识别的“建筑场景需求解析规则”、项目验收的“施工文档检索与报告生成逻辑”），通过多轮迭代适配建筑设计业务需求；
- **主流程开发与测试**: 搭建“用户输入→意图识别→智能体分发→MCP 调用→结果返回”全业务链路，覆盖差旅查询、智能审批、项目知识检索等核心场景；设计多维度测试用例（如复杂差旅变更、多项目并行检索），验证系统稳定性与准确性。

项目优化:

- **模型优化**: 构建意图分类及槽位提取数据集，对 GLM-4-32B 模型进行 LoRA 微调，使其适配建筑领域相关知识，提升意图分类和槽位提取的效果；将微调后的模型使用 GPTQ 进行量化，缩小体积，加快推理速度。
- **流程优化**: 对于复杂的多意图问题或者 Agent 需要调用多个无依赖关系的 Agent 或工具时，使用并行的方式进行调用，加快执行效率；
- **Agent 优化**: 通过构建本地知识库，将整理好的公司差旅标准、项目资料、用户信息和财务数据等信息存储到 milvus 和 MySQL 中，通过 RAG 系统进行内容检索，提高生成质量。

最终成果:

- 通过多智能体架构，完成多功能整合，极大降低了用户的使用成本，员工满意度达 94%；
- 系统高效覆盖建筑服务需求，多智能体并行调度与流程优化显著提升任务完成效率，复杂查询提速近一倍。

项目名称: 基于 RAG 的设计问答助手 (ArchiRAG)

2024.4-至今

项目描述: 针对设计人员海量知识检索难、规范更新适应慢导致效率低、易出错的痛点，融合结构化知识库与 RAG 技术开发 ArchiRAG，提供精准及时的知识支持，保障设计质量合规性，提升工作效率。

技术栈: Python、LangChain、Milvus、BERT、BM25、Cross-Encoder Reranker、Qwen2.5-14B、OCR

项目职责:

- **文档收集、预处理**: 针对 PDF、Word、PPT、图片等多格式文件，自定义加载器(继承 LangChain 的 BaseLoader 类，PDF 用 PyMuPDF+PaddleOCR 提取，Word/PPT 用 python-docx 处理块信息)，按文档类型选中文递归切分器或语义切分器，完成 10 万+条数据构建；
- **向量数据库构建**: 设计 Milvus 集合(含主键、稠密/稀疏向量、父块信息等字段)，用 BGE-M3 模型将文本编码为两类向量，稠密向量设 IVF_FLAT 索引、稀疏向量设稀疏倒排索引，支持混合检索；
- **高频问题缓存**: 设计 MySQL 表存储高频问答对与历史对话，用 BM25+Softmax 计算查询与高频问题相似度(阈值 0.90 判定同一问题)；Redis 缓存高相似问题，实现匹配问题的毫秒级响应，降低系统响应时长；
- **RAG 检索系统**: 训练 BERT 意图识别模块(准确率 93%)，设计 3 种 query 改写策略；通过加权排名实现混合检索，再用 BGE-reranker-large 重排序；
- **RAG 系统评估**: 构建测试集并通过 RAGAS 框架完成全流程量化评测，得出忠实度 93%、答案相关性 90%、上下文相关性 79%、上下文召回率 83%。

项目优化:

- 针对 PDF/PPT 中图片、表格等内容，引入 OCR 工具与多模态大模型提取图文信息，提升知识覆盖完整性。
- 设计多策略 query 改写机制(HyDE、子查询分解、回溯问题、历史问题改写)，提升模糊查询的召回率；
- 构建层级文档储存机制，通过混合检索提升召回准确率，引入 Rerank 模块进行重排序；
- 对 Qwen2.5-14B 模型进行 LoRA 微调，适配建筑领域术语与回答风格，显著提升回答专业性与流畅度。

项目成果:

- 系统响应时效缩短 55%，自动应答率超 80%；
- 设计人员满意度达 94%，显著提升回答准确率与工作效率。

项目名称: 建筑规范辅助查询项目 (GB-Graph)2023.5-2023.12

项目描述: 项目基于知识图谱与 NLP 算法构建智能化平台, 旨在提升建筑审图部门的规范查询效率, 增强其智能审图水平, 帮助审图人员及设计师更高效、准确地确定建筑规范条文, 提高整个设计和审查效率。

技术栈: Casrel、BERT、BiLSTM-CRF、TF-IDF、GBDT、doccano 、Neo4j

项目职责:

- **全流程架构与实现:** 参与从数据采集、清洗到知识融合与储存的全链路设计, 构建基于 Neo4j 的知识图谱;
- **数据构建与关系抽取:** 组织数据标注构建高质量训练集, 设计 Casrel 联合抽取模型, 实现实体与关系抽取;
- **知识融合:** 通过实体标准库与 TF-IDF 相似度计算实现实体消歧, 利用 Neo4j 完成图数据导入;
- **NLP 核心模型开发:** 构建问答系统 NLU 模块, 融合逻辑回归与 GBDT 实现意图识别 (F1=0.96) ; 采用 BERT+MLP 与 BiLSTM-CRF 分别实现高精度意图分类 (F1=0.97) 与实体识别 (F1=0.95) ;
- **模型优化与系统集成:** 通过调参、结构改进及模型升级 (如使用 chinese-roberta) 提升模型性能与推理效率; 将 NLP 模型与知识图谱、对话模块集成, 构建端到端智能问答流水线。

项目成果:

- 成功交付高性能 NLP 模型, 其中 Casrel 联合抽取模型在测试集上 NER: F1 为 0.94, RE: F1 为 0.89;
- 落地智能平台, 实现规范秒查、设计自查, 推动从人工查阅到智能查询的转变, 提升设计与审图效率。

项目名称: 基于多模型融合的设计公司智能邮件分类与路由系统2022.6-2023.1

项目描述: 开发智能邮件分类与路由系统, 利用多模型融合自动识别并分类设计公司邮件为 7 类, 实现自动转发, 显著提升邮件处理效率与准确率。

技术栈: RandomForest、FastText、Bert、BiLSTM

主要职责:

- **主导数据预处理与特征工程:** 清洗原始邮件数据, 进行分词处理, 构建设计领域专业术语词典, 并运用过采样技术解决样本不平衡问题;
- **负责多模型开发与训练:** 搭建并训练了 RandomForest、FastText、BERT 以及基于知识蒸馏的 BiLSTM 学生模型;
- **推进模型优化与系统集成:** 通过超参数调优和交叉验证优化模型, 最终确定以蒸馏后 BiLSTM 模型为核心、FastText 为降级备选的部署方案;
- **实现系统部署与效果验证:** 成功部署系统, 七大类邮件整体分类准确率达 93.2%, F1-score 为 0.93, 关键类别召回率超 95%, 邮件处理速度提升 20 倍。

最终成果:

- 建立高精度邮件分类系统, 整体准确率 93.2%, 关键业务邮件召回率超 95%。

自我评价

- 具备扎实的深度学习与自然语言处理理论基础, 深耕数据建模与系统优化, 拥有相关落地实践经验;
- 坚持持续学习, 紧盯大模型应用、检索增强技术前沿, 具备快速学习与知识迁移能力, 能高效转化新技术;
- 善于倾听总结, 可快速拆解多方核心需求、平衡利益点, 推动团队协作, 助力营造积极向上的团队氛围。